

Современные методы анализа данных и машинного обучения

Тема 2. Лекция 2

Задачи анализа данных, аналитики, основы EDA


Юрий Саночкин

ysanochkin@hse.ru

НИУ ВШЭ, 2026


Какие бывают задачи программирования?

Может быть такое




Что является целью? А результатом?

А может быть такое




А здесь что является целью и результатом?

Какие бывают задачи программирования?




Какие бывают задачи программирования?




Но это только первый уровень погружения,
с которым мы уже частично знакомы! :)

Какие бывают задачи *анализа данных*?


Может быть такое



Или такое




Или такое



Какие бывают задачи анализа данных?

Так какую же классификацию здесь можно
сделать?

Какие бывают задачи анализа данных?



Какие бывают задачи анализа данных?



DATA ANALYST

Collects, processes, and performs analysis on large data sets.


DATA SCIENTIST

Uses statistical techniques, data analysis methods, and machine learning to analyze data.


DATA ENGINEER

Builds and maintains data infrastructure and data systems, and sets up the data warehouses, data pipelines and databases.


Какие бывают задачи анализа данных?



Какие бывают задачи анализа данных?



Какие бывают задачи анализа данных?



Вот этим двум блокам предшествует прекрасный
этап под названием — EDA

Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA)

- Как проводит время среднестатистический DS?

Exploratory Data Analysis (EDA)

- Как проводит время среднестатистический DS?



Exploratory Data Analysis (EDA)

- Как проводит время среднестатистический DS?



Основная и очень важная
часть работы!

Exploratory Data Analysis (EDA)


- Как проводит время среднестатистический DS?



Основная и очень важная часть работы!

Кстати, в чём заключается разница между этими тремя этапами? В каком порядке они выполняются и как связаны с остальными?

WHAT DATA SCIENTISTS SPEND THE MOST TIME DOING



Собственно, оригинальная картинка из исследования, проведенного в 2016 году

Как мы переходим от матриц к анализу данных

- До сих пор мы много обсуждали и работали с матрицами и многомерными векторами
- А вообще, зачем они нам? Как они помогут в задаче анализа данных?

Как мы переходим от матриц к анализу данных

- До сих пор мы много обсуждали и работали с матрицами и многомерными векторами
- А вообще, зачем они нам? Как они помогут в задаче анализа данных?
- Ответим на этот вопрос, введя более строгую, чем раньше, математическую формализацию на примере конкретной задачи

Пример задачи

- Сеть ресторанов
- Хотим открыть еще один
- Несколько вариантов размещения
- Какой из вариантов принесет максимальную прибыль?

kaggle.com, TFI Restaurant Revenue Prediction

Принятые обозначения

- x — объект, то есть в нашем случае одно конкретное расположение ресторана
- $\mathbb{X}$ — пространство всех возможных объектов, то есть все возможные расположения ресторанов
- y — целевая переменная, интересующая нас, то есть прибыль ресторана в течение первого года работы (для конкретного места)
- $\mathbb{Y}$ — пространство всех возможных значений ответов, то есть в нашем случае $\mathbb{R}$

Объекты и признаки

- Объекты — абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features — числовые характеристики объектов
- d — количество признаков
- $x = (x_1, x_2, \dots, x_d)$ — признаковое описание


Объекты и признаки

- Объекты — абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features — числовые характеристики объектов
- d — количество признаков
- $x = (x_1, x_2, \dots, x_d)$ — признаковое описание

Что собой представляет x ? Что собой представляют x_i ?

Объекты и признаки

- Объекты — абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features — числовые характеристики объектов
- d — количество признаков
- $x = (x_1, x_2, \dots, x_d)$ — признаковое описание



Вектор

Объекты и признаки

- Объекты — абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features — числовые характеристики объектов
- d — количество признаков
- $x = (x_1, x_2, \dots, x_d)$ — признаковое описание



Объекты и признаки

Case	Attributes				Decision
	Length	Height	Width	Weight	Quality
1	4.7	1.8	1.7	1.7	high
2	4.5	1.4	1.8	0.9	high
3	4.7	1.8	1.9	1.3	high
4	4.5	1.8	1.7	1.3	medium
5	4.3	1.6	1.9	1.7	medium
6	4.3	1.4	1.7	0.9	low
7	4.5	1.6	1.9	0.9	very-low
8	4.5	1.4	1.8	1.3	very-low

Объекты и признаки

Case	Attributes				Decision
	Length	Height	Width	Weight	Quality
1	4.7	1.8	1.7	1.7	high
2	4.5	1.4	1.8	0.9	high
3	4.7	1.8	1.9	1.3	high
4	4.5	1.8	1.7	1.3	medium
5	4.3	1.6	1.9	1.7	medium
6	4.3	1.4	1.7	0.9	low
7	4.5	1.6	1.9	0.9	very-low
8	4.5	1.4	1.8	1.3	very-low

Целевая
переменная
(target)

Признаки (атрибуты, фичи, features)

Объекты и признаки

- Чем можно описать расположение ресторана?



Объекты и признаки

- Чем можно описать расположение ресторана?
- Про демографию:
 - Средний возраст жителей ближайших кварталов
 - Динамика количества жителей
- Про недвижимость:
 - Средняя стоимость квадратного метра жилья поблизости
 - Количество школ, банков, магазинов, заправок
 - Расстояние до ближайшего конкурента
- Про дороги:
 - Среднее количество машин, проезжающих мимо за день

Матрица данных

- Таким образом, имеем k возможных расположений ресторанов (k объектов) и d характеристик, описывающих каждое из подобных расположений (d признаков).
- Таблица A , в которой записаны эти данные, представляет собой матрицу $A_{k \times d}$, где каждая строка — это вектор одного из объектов; а каждый столбец, соответственно, отвечает за один конкретный признак.

Матрица данных

- Таким образом, имеем k возможных расположений ресторанов (k объектов) и d характеристик, описывающих каждое из подобных расположений (d признаков).
- Таблица A , в которой записаны эти данные, представляет собой матрицу $A_{k \times d}$, где каждая строка — это вектор одного из объектов; а каждый столбец, соответственно, отвечает за один конкретный признак.
- Мы перешли от абстрактных объектов, взятых напрямую из интересующей нас предметной области, — к матрице, хранящей в себе признаковое описание каждого объекта.
- Значит, теперь можем работать с данными, представленными в виде матрицы, просто как с математическим объектом! Чтд.

Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA)

- Exploratory Data Analysis (EDA, разведочный анализ данных) – анализ основных свойств данных, нахождение в них общих закономерностей, распределений и аномалий, построение начальных моделей.
- В широком смысле, EDA – это первичное погружение в данные.


Exploratory Data Analysis (EDA)

- Exploratory Data Analysis (EDA, разведочный анализ данных) – анализ основных свойств данных, нахождение в них общих закономерностей, распределений и аномалий, построение начальных моделей.
- В широком смысле, EDA – это первичное погружение в данные.
- В рамках особенно начальных этапов EDA активно используются всевозможные визуализации.


Exploratory Data Analysis (EDA)

- Важной частью и последним этапом EDA является Feature Engineering (инжиниринг признаков). Иногда его и вовсе выделяют в отдельный, независимый этап, осуществляемый по завершении основного EDA.
- Feature Engineering крайне важен в анализе; мы разберем его чуть далее.

Exploratory Data Analysis (EDA)



Exploratory Data Analysis (EDA)



Общий пайплайн работы дата-саентиста

Exploratory Data Analysis (EDA)

- С учетом обсужденного ранее, как вы понимаете, в чем заключаются основные цели EDA?

Exploratory Data Analysis (EDA)


- С учетом обсужденного ранее, как вы понимаете, в чем заключаются основные цели EDA?
 - Максимальное «проникновение» в данные.
 - Выявление основных структур.
 - Выбор наиболее важных переменных.
 - Обнаружение отклонений и аномалий.
 - Проверка первичных гипотез (предположений).
 - Разработка начальных моделей.

Exploratory Data Analysis (EDA)


Основной постулат EDA:

«Мусор на входе – мусор на выходе»

Exploratory Data Analysis (EDA)



Exploratory Data Analysis (EDA)



Основные шаги первичного EDA

Feature Engineering

Feature Engineering

- Feature Engineering (инжиниринг признаков) – это процесс трансформации существующих признаков или создания на их основе новых с целью улучшения работы алгоритмов машинного обучения и нахождения более сложных зависимостей.

Feature Engineering

`Coming up with features is difficult, time-consuming, requires expert knowledge.
"Applied machine learning" is basically feature engineering.'

Andrew Ng, Machine Learning and AI via Brain simulations

Feature Engineering

- Feature Engineering (инжиниринг признаков) – это процесс трансформации существующих признаков или создания на их основе новых с целью улучшения работы алгоритмов машинного обучения и нахождения более сложных зависимостей.

Feature Engineering


- Feature Engineering (инжиниринг признаков) – это процесс трансформации существующих признаков или создания на их основе новых с целью улучшения работы алгоритмов машинного обучения и нахождения более сложных зависимостей.
- Feature Engineering – это финальный и самый длительный этап EDA.
- Зачастую повторяется множество раз с начала, пока качество не начинает достигать требуемого уровня.

Feature Engineering

- Какие составные части можно выделить в рамках Feature Engineering?

Feature Engineering

- Какие составные части можно выделить в рамках Feature Engineering?



Feature Extraction

- Feature Extraction (извлечение признаков) – это процесс конструирования новых признаков из исходных данных.
- Извлечение признаков направлено на выявление и создание информативных характеристик, которые могут лучше представлять структуру данных для последующего анализа и применения моделей.

Feature Transformation

- Feature Transformation (трансформация признаков) – этап, представляющий собой изменение существующих признаков в целях улучшения их пригодности для моделирования.
- Применяются, например, нормализация, стандартизация, дискретизация значений, изменения шкал, кодирование, использование математических функций для преобразования значений и тд.

Feature Selection

- Feature Selection (отбор признаков) – процесс, направленный на выделение наиболее значимых и релевантных признаков из данных, что помогает снизить размерность датасета, избавиться от ненужных столбцов и повысить эффективность последующего моделирования и анализа.

Типы признаков

Типы признаков

- Признаки, описывающие наши объекты, могут иметь совершенно разную природу.
- Почему для нас вообще важно как-то классифицировать признаки, которые мы можем встретить?

Типы признаков

- Признаки, описывающие наши объекты, могут иметь совершенно разную природу.
- Почему для нас вообще важно как-то классифицировать признаки, которые мы можем встретить?
- Методы, алгоритмы, да и вообще зачастую сама постановка задачи анализа данных – могут очень сильно разниться, в зависимости от того, с какими признаками мы имеем дело.

Типы признаков

- Введем обозначение:
- D_j — множество значений признаков

Бинарные признаки

- $D_j = \{0, 1\}$
- Приведите примеры

Бинарные признаки

- $D_j = \{0, 1\}$
- Приведите примеры
- Брали ли вы раньше кредит в этом банке?
- Доход клиента выше среднего по городу?
- Цвет фрукта — зеленый?

Вещественные признаки

- $D_j = \mathbb{R}$ (или какое-то бесконечное подмножество $\mathbb{R}$)
- Приведите примеры

Вещественные признаки

- $D_j = \mathbb{R}$ (или какое-то бесконечное подмножество $\mathbb{R}$)
- Приведите примеры
- Возраст
- Площадь квартиры
- Количество звонков в колл-центр

Категориальные признаки

- D_j — неупорядоченное конечное множество
- Приведите примеры

Категориальные признаки

- D_j — неупорядоченное конечное множество
- Приведите примеры
- Цвет глаз
- Страна
- Образование (может быть упорядоченным, если смотреть степень)

Категориальные признаки

- D_j — неупорядоченное конечное множество
- Приведите примеры
- Цвет глаз
- Страна
- Образование (может быть упорядоченным, если смотреть степень)
- Очень трудны в обработке при анализе данных
- К этому мы еще вернемся :)

Порядковые признаки

- D_j — упорядоченное конечное множество
- Приведите примеры

Порядковые признаки

- D_j — упорядоченное конечное множество
- Приведите примеры
- Военское звание
- Роль в фильме (первого плана, второго плана, массовка)
- Тип населенного пункта

Типы признаков

- Итак, типы признаков:
 - Бинарные
 - Вещественные (числовые)
 - Категориальные и порядковые
- Может быть, мы что-то забыли?

Типы признаков

- Итак, типы признаков:
 - Бинарные
 - Вещественные (числовые)
 - Категориальные и порядковые
- Может быть, мы что-то забыли?
- Мы очень много чего забыли! 😊
- Тексты, изображения, звук, ... — все эти источники данных формируют своё, специфичное признаковое пространство.

Типы признаков

- Итак, типы признаков:
 - Бинарные
 - Вещественные (числовые)
 - Категориальные и порядковые
- Может быть, мы что-то забыли?
- Мы очень много чего забыли! 😊
- Тексты, изображения, звук, ... — все эти источники данных формируют своё, специфичное признаковое пространство.
- А ещё... Временные ряды!

Типы признаков

- Итак, типы признаков:
 - Бинарные
 - Вещественные (числовые)
 - Категориальные и порядковые
- Может быть, мы что-то забыли?
- Мы очень много чего забыли! 😊
- Тексты, изображения, звук, ... — все эти источники данных формируют своё, специфичное признаковое пространство.
- А ещё... Временные ряды!
- Они тоже находятся в совершенно обособленном кластере.

Временные ряды

- Что такой временной ряд, как вы это понимаете?

Временные ряды

- Что такой временной ряд, как вы это понимаете?
- В анализе данных временной ряд — это данные, имеющие какую-либо временную отметку с постоянной частотой дискретизации.


Временные ряды

- Что такой временной ряд, как вы это понимаете?
- В анализе данных временной ряд — это данные, имеющие какую-либо временную отметку с постоянной частотой дискретизации.
- Приведите примеры любых временных рядов:

Временные ряды

- Цена курса доллара по дням
- Количество заболевших коронавирусом по месяцам
- Текущая цена криптовалюты по минутам
- Количество ретвитов в твиттер-аккаунте Трампа по дням
- Среднесуточное количество осадков на Манхэттене с 2014 по 2024 год по месяцам
- ...

Временные ряды



Временные ряды

- Как уже было указано ранее, временные ряды формируют очень специфическое признаковое пространство.
- Для анализа такого признакового пространства требуются свои специальные методы и особый математический аппарат.

Временные ряды

- Как уже было указано ранее, временные ряды формируют очень специфическое признаковое пространство.
- Для анализа такого признакового пространства требуются свои специальные методы и особый математический аппарат.
- К счастью, в рамках нашего курса всё это будет отдельно и подробно рассмотрено в дальнейшем!
- Stay tuned! 😊

Работа с пропусками в данных

Работа с пропусками в данных

- Вспомним еще раз:
- Таблица A , в которой записаны данные, представляет собой матрицу $A_{k \times d}$, где каждая строка — это вектор одного из объектов; а каждый столбец, соответственно, отвечает за один конкретный признак.

Работа с пропусками в данных

- Вспомним еще раз:
- Таблица A , в которой записаны данные, представляет собой матрицу $A_{k \times d}$, где каждая строка — это вектор одного из объектов; а каждый столбец, соответственно, отвечает за один конкретный признак.
- Могут ли в матрице A быть какие-то пропуски?
- В математике нет, а в жизни — да, подсказывает нам название раздела.

Работа с пропусками в данных

- Откуда берутся пропуски?

Работа с пропусками в данных

- Откуда берутся пропуски?
- Ошибки при сборе или переносе/записи данных
- Некачественная работа с данными
- Отсутствие информации о чем-либо
- и т.д.

Работа с пропусками в данных

- Чем пропуски плохи?
- Почему они вредят?

Работа с пропусками в данных

- Чем пропуски плохи?
- Почему они вредят?
- Сокращение числа значений для анализа
- Смещенность выборки и выборочных характеристик (выборочное среднее, выборочная дисперсия, ...)
- Невозможность применять ряд алгоритмов и методов, работающих с числами
- и многое другое


Работа с пропусками в данных

- И как же можно бороться с пропусками?

Работа с пропусками в данных

- И как же можно бороться с пропусками?
- Есть разные подходы

Работа с пропусками в данных



Заполнение пропусков средним значением

- Заполнение пропусков средним значением (Mean Substitution) или другие варианты этого подхода: заполнение нулем, заполнение медианой и тому подобные — название метода во всех случаях говорит само за себя.

Заполнение пропусков средним значением

- Заполнение пропусков средним значением (Mean Substitution) или другие варианты этого подхода: заполнение нулем, заполнение медианой и тому подобные — название метода во всех случаях говорит само за себя.
- Всем вариациям данного метода свойственны одни и те же недостатки:

Заполнение пропусков средним значением

- Всем вариациям данного метода свойственны одни и те же недостатки:




Рисунок 1а — Распределение значений непрерывной характеристики ДО заполнения пропусков




Рисунок 1б — Распределение значений непрерывной характеристики ПОСЛЕ заполнения пропусков

Заполнение пропусков на основе регрессионных моделей

- Данный метод заключается в том, что пропущенные значения заполняются с помощью модели линейной регрессии или её вариаций, построенной на известных значениях набора данных.

Заполнение пропусков на основе регрессионных моделей

- Данный метод заключается в том, что пропущенные значения заполняются с помощью модели линейной регрессии или её вариаций, построенной на известных значениях набора данных.




Рисунок 2а — Заполнение пропусков на основе линейной регрессии




Рисунок 2б — Заполнение пропусков на основе стохастической линейной регрессии

Другие способы работы с пропусками

- Можно постараться эмулировать случайную генерацию с неким распределением, приближенным к статистическим данным столбца, по которому мы хотим заполнить пропуски. То есть чтобы данные, сгенерированные случайно, были «похожи» по распределению на те, что уже есть.

Другие способы работы с пропусками

- Можно постараться эмулировать случайную генерацию с неким распределением, приближенным к статистическим данным столбца, по которому мы хотим заполнить пропуски. То есть чтобы данные, сгенерированные случайно, были «похожи» по распределению на те, что уже есть.
- Можно использовать методы машинного обучения для заполнения пропусков на основе значений других столбцов.

Другие способы работы с пропусками

- Можно постараться эмулировать случайную генерацию с неким распределением, приближенным к статистическим данным столбца, по которому мы хотим заполнить пропуски. То есть чтобы данные, сгенерированные случайно, были «похожи» по распределению на те, что уже есть.
- Можно использовать методы машинного обучения для заполнения пропусков на основе значений других столбцов.
- Или можно просто выкинуть данные)

Другие способы работы с пропусками

- Можно постараться эмулировать случайную генерацию с неким распределением, приближенным к статистическим данным столбца, по которому мы хотим заполнить пропуски. То есть чтобы данные, сгенерированные случайно, были «похожи» по распределению на те, что уже есть.
- Можно использовать методы машинного обучения для заполнения пропусков на основе значений других столбцов.
- Или можно просто выкинуть данные)
 - Причем выкинуть можно как строки с пропусками, так и столбцы с пропусками, и это тоже разные методы

Другие способы работы с пропусками

- Можно постараться эмулировать случайную генерацию с неким распределением, приближенным к статистическим данным столбца, по которому мы хотим заполнить пропуски. То есть чтобы данные, сгенерированные случайно, были «похожи» по распределению на те, что уже есть.
- Можно использовать методы машинного обучения для заполнения пропусков на основе значений других столбцов
- Или можно просто выкинуть данные)
 - Причем выкинуть можно как строки с пропусками, так и столбцы с пропусками, и это тоже разные методы

И как же понять, когда какой способ применять?

Univariate analysis

Univariate analysis



- Univariate analysis (или анализ одной переменной) — важный этап EDA, в основном базирующийся на теории вероятностей и математической статистике и предполагающий использование большого количества различных визуализаций одной переменной.

Univariate analysis

- Univariate analysis (или анализ одной переменной) — важный этап EDA, в основном базирующийся на теории вероятностей и математической статистике и предполагающий использование большого количества различных визуализаций одной переменной.
- Из визуализаций в Univariate analysis чаще всего используются: PDF, CDF, Boxplot, Violin plots, Distribution plots и ряд других.


```
In [42]: df.average_monthly_hours.hist()  
plt.plot()
```

Out[42]: []



Теория вероятностей и математическая статистика

- Краткое напоминание основных понятий, терминов и блоков, которые понадобятся нам из теории вероятностей и математической статистики (если забыли и/или путаетесь и чувствуете себя неуверенно — лучше повторите потом всё сами ещё раз отдельно).



Базовые понятия

- Случайная величина — в теории вероятностей, величина, принимающая в зависимости от случая те или иные значения с определёнными вероятностями.

Базовые понятия

- Случайная величина — в теории вероятностей, величина, принимающая в зависимости от случая те или иные значения с определёнными вероятностями.
- Говоря более простым языком, любая измеримая величина, на которую воздействует какой-то элемент случайности.
 - Примером случайной величины может служить число, выпавшее на игральном кубике при случайном броске; или расстояние от точки падения снаряда до цели; или доход случайно взятого человека; или любой другой пример измеримой величины, на которую действует что-то случайное.


Базовые понятия

- Законом распределения (или просто распределением) случайной величины X называют правило, позволяющее находить вероятность попадания значений X в любой заданный числовой промежуток.

Базовые понятия


- Законом распределения (или просто распределением) случайной величины X называют правило, позволяющее находить вероятность попадания значений X в любой заданный числовой промежуток.
- Говоря более простым языком, распределение полностью характеризует случайный процесс, с которым мы работаем.
 - Всевозможные характеристики: матожидание, дисперсию, ...; график плотности, график распределения, квантили, ... — в общем, всё, что может как-то описать наш процесс, — вот всё это и задаёт распределение случайной величины.

Распределения



Непрерывные


- Нормальный закон распределения (закон Гаусса)
- Логарифмически нормальное распределение
- Гамма-распределение
- Экспоненциальный закон распределения



Дискретные


- Распределение Пуассона
- Геометрическое распределение
- Биномиальное распределение
- Бернулли

Распределения



Непрерывные

- Нормальный закон распределения (закон Гаусса)
- Логарифмически нормальное распределение
- Гамма-распределение
- Экспоненциальный закон распределения




Дискретные

- Распределение Пуассона
- Геометрическое распределение
- Биномиальное распределение
- Бернулли

И, конечно, многие другие!


Распределения



Нормальное



Равномерное



Логнормальное




Гамма-распределение




Экспоненциальное




Вейбулла



Биномальное




Пуассона



Геометрическое


Функция распределения

- Функцией распределения случайной величины X называется функция $F(x)$, выражающая для каждого x вероятность того, что случайная величина X примет значение, меньшее x .



Функция плотности


- Функцией плотности (плотностью распределения или просто плотностью) $f(x)$ непрерывной случайной величины X называется производная ее функции распределения.



Функция плотности

- Один из главных способов задания распределения случайной величины. Может быть получена аппроксимацией из гистограммы.
- График плотности $f(x)$ называется кривой распределения.


Вероятность попадания случайной величины в интервал $[a,b]$:




$$P(a \leq X \leq b) = \int_a^b f(x) dx = F(b) - F(a)$$

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$


Распределение Бернулли




Равномерное распределение



Нормальное распределение



Нормальное распределение



Зеленой линией
обозначено стандартное
нормальное
распределение

Нормальное распределение

- Нормальное распределение отличается от других распределений своей особой природой.
- Физическая величина подчиняется нормальному распределению, когда она подвержена влиянию огромного числа одинаковых случайных помех.

Нормальное распределение

- Нормальное распределение может быть получено с использованием следующей формулы:

$$y = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x - \mu)^2}{2\sigma^2}}$$

μ = Mean

σ = Standard Deviation

$\pi \approx 3.14159 \dots$

$e \approx 2.71828 \dots$

Нормальное распределение

- Нормальное распределение может быть получено с использованием следующей формулы:

$$y = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x - \mu)^2}{2\sigma^2}}$$

μ = Mean

σ = Standard Deviation


$\pi \approx 3.14159 \dots$

$e \approx 2.71828 \dots$

- Алгоритмы ML, которым необходимо нормальное распределение признаков:
 - Наивный Байесовский классификатор
 - Модели на основе МНК
 - Квадратичный дискриминантный анализ
 - Линейный дискриминантный анализ
 - И многие другие

Правило 68-95-99,7 для нормального распределения (правило трех сигм)

- Для нормального распределения количество значений, отличающихся от среднего на число, меньшее чем одно стандартное отклонение, составляет 68,27 % выборки.
- В то же время количество значений, отличающихся от среднего на два стандартных отклонения, составляет 95,45 %, а на три стандартных отклонения — 99,73 %.



Выбросы в данных

Выбросы в данных



- В статистике выбросы (outliers) – это экстремальные значения во входных данных, которые находятся далеко за пределами других наблюдений.
- Выбросы неестественны и могут зашумлять наши данные, а также существенно искажать метрики, влияя на качество алгоритмов.

Методы обнаружения выбросов

Методы обнаружения выбросов


- Статистические тесты

Z-value $Z_i = \frac{|x_i - \mu|}{\sigma}$ Kurtosis $\frac{1}{n} \sum_{i=1}^n Z_i^4$



Методы обнаружения выбросов

- BoxPlot (ящик с усами)



Продвинутые методы обнаружения

- Помимо классических методов, выбросам (а также аномалиям) посвящен целый раздел в ML — Anomaly detection.

Продвинутые методы обнаружения


- Помимо классических методов, выбросам (а также аномалиям) посвящен целый раздел в ML — Anomaly detection.
- Кстати, как вы понимаете, в чём заключается разница между аномалиями и выбросами?

Продвинутые методы обнаружения

- Выявление аномалий (также обнаружение выбросов) — это опознавание во время интеллектуального анализа данных редких событий или наблюдений, которые вызывают подозрения ввиду существенного отличия от большей части объектов.
- Обычно аномальные данные характеризуют некоторый вид проблемы, такой как мошенничество в банке, структурный дефект, медицинские проблемы или ошибки в тексте.

Продвинутые методы обнаружения

- Кроме того, отдельным блоком стоит детектирование аномалий во временных рядах, что также тесно связано с проблемой неоднородности временных рядов. Об этом мы ещё поговорим!



Multivariate analysis


Multivariate analysis

- Multivariate analysis (или анализ многих переменных) — ещё один крайне важный этап EDA, также базирующийся на теории вероятностей и математической статистике и описывающий взаимодействие различных признаков друг с другом

Multivariate analysis

- Multivariate analysis (или анализ многих переменных) — ещё один крайне важный этап EDA, также базирующийся на теории вероятностей и математической статистике и описывающий взаимодействие различных признаков друг с другом
- В рамках Multivariate analysis чаще всего используются:
 - Scatter plot (визуализация),
 - PCA — метод главных компонент, многомерный дисперсионный анализ (о нем мы ещё будем подробно говорить),
 - SNE/t-SNE.

Multivariate analysis



Коллинеарность признаков



- Коллинеарными называются признаки, которые сильно коррелируют друг с другом.
- В машинном обучении это приводит к снижению производительности обобщения данных из-за высокой дисперсии и меньшей интерпретируемости модели.

Коллинеарность признаков

- Корреляция — статистическая взаимосвязь между случайными величинами; не всегда является достаточным условием причинно-следственной связи.


Коллинеарность признаков

- Корреляция — статистическая взаимосвязь между случайными величинами; не всегда является достаточным условием причинно-следственной связи.



Коллинеарность признаков

- Коэффициент корреляции принимает значения от -1 до +1. Чем выше значение коэффициента корреляции по модулю, тем больше зависимость между величинами.
- Корреляция бывает положительной и отрицательной.



Коэффициент корреляции Пирсона

- Коэффициент корреляции Пирсона (коэффициент корреляции) представляет собой статистику, которая измеряет величину линейной связи (корреляцию) между двумя переменными.
- Он принимает значения от -1 до +1. Значение коэффициента +1 означает наличие полной положительной линейной связи, а значение -1 – наличие полной отрицательной линейной связи.


$$r_{xy} = \frac{\sum (x_i - \bar{x}) \times (y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \times \sum (y_i - \bar{y})^2}}$$

$\bar{x}$ – математическое ожидание ряда x ;

$\bar{y}$ – математическое ожидание ряда y ;

Коэффициент корреляции Пирсона

- Коэффициент корреляции Пирсона – не самая лучшая метрика для проверки коллинеарности признаков:




Другие коэффициенты корреляции

- Коэффициент ранговой корреляции Кендалла (для нелинейных зависимостей)
- Коэффициент ранговой корреляции Спирмена (для нелинейных зависимостей)

Другие коэффициенты корреляции

How to Choose a Feature Selection Method



Кодирование признаков

Кодирование признаков

- Как подать модели на вход такие данные?

	Name	Platform	Year	Genre	Publisher
1	Super Mario Bros.	NES	1985.0	Platform	Nintendo
2	Mario Kart Wii	Wii	2008.0	Racing	Nintendo
3	Wii Sports Resort	Wii	2009.0	Sports	Nintendo
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	Nintendo
5	Tetris	GB	1989.0	Puzzle	Nintendo
6	New Super Mario Bros.	DS	2006.0	Platform	Nintendo

Кодирование признаков

- Как подать модели на вход такие данные?

	Name	Platform	Year	Genre	Publisher
1	Super Mario Bros.	NES	1985.0	Platform	Nintendo
2	Mario Kart Wii	Wii	2008.0	Racing	Nintendo
3	Wii Sports Resort	Wii	2009.0	Sports	Nintendo
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	Nintendo
5	Tetris	GB	1989.0	Puzzle	Nintendo
6	New Super Mario Bros.	DS	2006.0	Platform	Nintendo

Номинальный признак

Категориальные признаки

Ordinal Encoding (Label Encoding)

- Метод реализован в классе `sklearn.preprocessing.LabelEncoder`.

Original Encoding	Ordinal Encoding
Poor	1
Good	2
Very Good	3
Excellent	4

Ordinal Encoding (Label Encoding)

- Метод реализован в классе `sklearn.preprocessing.LabelEncoder`.

Original Encoding	Ordinal Encoding
Poor	1
Good	2
Very Good	3
Excellent	4

Какие преимущества и недостатки у метода?
В каких случаях он эффективен, а в каких неэффективен?

One-hot-encoding (Dummy encoding)

- Следующий способ – dummy-кодирование, также называемое — one-hot. Суть заключается в создании дополнительных N признаков (столбцов), где N – количество уникальных категорий.
- Новые признаки принимают значения 0 или 1 в зависимости от принадлежности к категории.
- Метод реализован в классе `sklearn.preprocessing.OneHotEncoder`.

One-hot-encoding (Dummy encoding)

id	color
1	red
2	blue
3	green
4	blue



id	color_red	color_blue	color_green
1	1	0	0
2	0	1	0
3	0	0	1
4	0	1	0

One-hot-encoding (Dummy encoding)

id	color
1	red
2	blue
3	green
4	blue



Какие преимущества и
недостатки у метода?
В каких случаях он эффективен,
а в каких неэффективен?

id	color_red	color_blue	color_green
1	1	0	0
2	0	1	0
3	0	0	1
4	0	1	0

One-hot-encoding (Dummy encoding)

id	color
1	red
2	blue
3	green
4	blue



Какие преимущества и
недостатки у метода?
В каких случаях он эффективен,
а в каких неэффективен?

id	color_red	color_blue	color_green
1	1	0	0
2	0	1	0
3	0	0	1
4	0	1	0

- One-hot encoder значительно увеличивает объем данных, что делает его неэффективным с точки зрения памяти. Частично эту проблему решает применение разреженных матриц и других техник.

One-hot-encoding (Dummy encoding)

id	color
1	red
2	blue
3	green
4	blue



Какие преимущества и
недостатки у метода?
В каких случаях он эффективен,
а в каких неэффективен?

id	color_red	color_blue	color_green
1	1	0	0
2	0	1	0
3	0	0	1
4	0	1	0


- Однако в некоторых случаях он может быть очень полезен и даже незаменим.

Кодирование вещественных столбцов

- Одна из наиболее часто встречающихся предпосылок статистических тестов заключается в том, что данные должны быть нормально распределены, что мы уже обсуждали ранее.

Кодирование вещественных столбцов


- Одна из наиболее часто встречающихся предпосылок статистических тестов заключается в том, что данные должны быть нормально распределены, что мы уже обсуждали ранее.




Нормальное распределение

Кодирование вещественных столбцов

- Одна из наиболее часто встречающихся предпосылок статистических тестов заключается в том, что данные должны быть нормально распределены, что мы уже обсуждали ранее.




Нормальное распределение




Смещение вправо

Кодирование вещественных столбцов


- Одна из наиболее часто встречающихся предпосылок статистических тестов заключается в том, что данные должны быть нормально распределены, что мы уже обсуждали ранее.



Нормальное распределение





Смещение вправо




Смещение влево

Log-transform



SQRT-transform



Кодирование вещественных столбцов

РАСПРОСТРАНЕННЫЕ ПРЕОБРАЗОВАНИЯ

Метод	Математическая операция	Подходит для:	Не подходит для:
Логарифм	$\ln(x)$ $\log_{10}(x)$	Данных, смещенных вправо	Нулевых значений
Квадратный корень	$\sqrt{x}$	особенно хорошо работает со степенями 10 более высокого порядка (например, 1000, 100000)	Отрицательных значений
Квадрат	x^2	Данных, смещенных вправо	Отрицательных значений
Корень кубический	$x^{1/3}$	Данных, смещенных влево	Отрицательных значений
Обратная дробь	$1/x$	Данных, смещенных вправо	Не так эффективен при нормализации, как логарифмическое преобразование

Литература и доп.материалы

- Топ 9 подходов в Feature Engineering:
 - <https://rubikscore.net/2021/06/29/top-9-feature-engineering-techniques>
- Детекция аномалий:
 - <https://dyakonov.org/2017/04/19/%D0%BF%D0%BE%D0%B8%D1%81%D0%BA-%D0%B0%D0%BD%D0%BE%D0%BC%D0%B0%D0%BB%D0%B8%D0%B9-anomaly-detection/>
- Гайд по EDA и FE:
 - <https://towardsdatascience.com/exploratory-data-analysis-feature-engineering-and-modelling-using-supermarket-sales-data-part-1-228140f89298>
 - <https://habr.com/ru/company/ods/blog/325422/>
 - <https://nagornyy.me/it/rabota-s-priznakami-kak-chast-mashinnogo-obucheniia>
 - <https://towardsdatascience.com/feature-engineering-for-machine-learning-3a5e293a5114#3abe>
 - <https://towardsdatascience.com/feature-engineering-for-machine-learning-3a5e293a5114>
- Случайные величины и их распределения:
 - [https://mipt.ru/education/chair/mathematics/study/methods/%D0%A1%D0%92%D0%B8%D0%A0%D0%A1%D0%B0%D0%BC%D0%B0%D1%80%D0%BE%D0%B2%D0%B0\(2\).pdf](https://mipt.ru/education/chair/mathematics/study/methods/%D0%A1%D0%92%D0%B8%D0%A0%D0%A1%D0%B0%D0%BC%D0%B0%D1%80%D0%BE%D0%B2%D0%B0(2).pdf)